Постобработка OCR паспорта РФ

Задача и критерий

По результату распознавания выбираю accept/reject и возвращаю десять полей для принятых документов. Правильным считаю принятие, если все поля совпадают с эталоном и паспорт проходит доступные проверки дат на 01.10.2026. Использую 3000 размеченных документов train и 2000 документов test без разметки. Исходных изображений не получаю.

Восстановление и модель

Объединяю строки по координатам, проверяю полноту полей, форматы и сроки замены паспорта в 20 и 45 лет с учётом 90 дней. Разбираю MRZ и контрольные цифры. В справочнике подразделений исправляю только единственную низкоуверенную замену буквы; падежи и сокращения не подменяю. Сохраняю латинские географические названия. Число правильных ответов с допустимыми датами увеличиваю с 1819 до 1910 из 3000.

Оцениваю надёжность полей через Pipeline: заполнение пропусков, масштабирование, кодирование категорий и классификатор. Сравниваю логистическую регрессию, случайный лес и бустинг на уровне документа и поля. Использую 24 признака: уверенности, геометрию, качество снимка, поддержку MRZ и справочника. ID и тексты ФИО в модель не передаю. Целевую метку задаю по правильности уже восстановленного ответа.

Проверка и основной режим

Повторы одного паспорта объединяю в группу. Использую пять внешних частей и внутреннюю calibration-часть. Для strict обучаю девять лесов с раздельной калибровкой, принимаю документ при единогласии. Каждый порог остаётся у своей модели; переобучением после калибровки его не переношу. Для численно одинаковых score сохраняю запас 1e-12.

Внешний seed	Проверено	Принято	FP
42	3000	27	0
123	3000	15	0
2026	3000	19	0

Основной режим выбираю под приоритет нулевых FP, но прямо фиксирую низкий охват: 0.9% в основном повторении. Число моделей выбираю по этим же проверкам; результат не называю независимой сертификацией. Повторения содержат одни и те же паспорта.

Экономика ошибок

Точного отношения цены FP и FN в условии нет. Задаю три сценария 5x, 10x и 25x как допущения, C_FN=1, стоимость L=k*FP+FN. FN считаю отказом от уже правильного восстановленного ответа с допустимыми датами. По этой стоимости внутри calibration выбираю семейство, гиперпараметры, агрегацию и порог: 18 конфигураций обучения, 27 вариантов с агрегациями. Метрики считаю на внешних частях.

Цена FP	Принято из 3000	FP	FN	L
5x	1809	36	137	317
10x	1782	30	158	458
25x	1710	25	225	850

У отклонения всех документов получаю стоимость 1910 при каждом k. Экономические варианты снижают стоимость, но допускают FP; выполнением буквального требования нуля ошибок их не считаю. Режимы доступны отдельно от strict.

Test, прогноз и ограничения

В answers.jsonl сохраняю 2000 строк; основной режим принимает 22 документа. Разметки test нет. Наиболее вероятное число ошибок по прогнозной модели - 0, ожидание около 0.76, 95%-ный прогнозный интервал 0-4. Использую OOF-риск по источникам, сглаживание Джеффриса и бета-биномиальный прогноз. Предполагаю переносимость риска внутри источника; малую выборку принятых и зависимость ошибок считаю ограничениями.

В 10 случаях VIZ и MRZ дают одинаковое ФИО, а эталон отличается. Без снимков не различаю общую ошибку OCR и неточность разметки. Эти случаи не исключаю из метрик и запреты по ID не добавляю. Полную юридическую действительность без реестра не устанавливаю. Дизайн разрабатываю на знакомом train; независимый test скрыт.

Запуск

```
python postprocess.py data/test_predictions.jsonl answers.jsonl
```

Использую CPU, локальные веса и справочник; сеть и train-разметка при запуске не нужны. Код восстановления общий для ноутбука и скрипта. Версии, пороги и хеши сохраняю в artifacts/model_manifest.json; прогнозы CV и результаты подбора - в artifacts/. Полный пересчёт: `python train.py --validate`. Справочник DaData / hflabs/fms-unit сохраняю с атрибуцией CC BY-SA 4.0 в reference/SOURCE.txt.